

NVIDIA GPU 產品線

Hopper 到 Blackwell

20251128 Allen Sun

NVIDIA 業界慣用語分層整理

| 層級 | 常用稱呼 | 範例 | 說明 |
|-------------|---|-----------------------------|----------------------|
| 消費級 GPU | GeForce RTX | RTX 5090 / RTX 5080 | 個人玩家、創作者、AI 開發入門 |
| 專業工作站 GPU | RTX Professional | RTX 6000 Ada / RTX PRO 6000 | 專業繪圖、工程設計、AI 開發環境 |
| 資料中心 GPU | NVIDIA Data Center GPU或簡稱「A/H/B 系列 GPU」 | A100 / H100 / B200 | AI 訓練、推理、大模型服務 |
| GPU 模組平台 | HGX | HGX H100 / HGX B200 | 伺服器用 GPU 主板 (SXM 版本) |
| 整機系統 / 超算平台 | DGX / GB200 / NVL72 | DGX H100 / GB200 NVL72 | 完整 AI 超算解決方案 |

功率區別 (TDP)：SXM 版本 (HGX) 的功耗通常遠高於 PCIe 版本 (例如 H100 SXM 是 700W，PCIe 則是 300-350W)，B200 SXM: ~**1000W** (比 H100 高 40%)。

實際業界溝通中常見的用語分層

| 常見說法 | 實際含義 | 對應技術層級 |
|-------------------|-----------------------------------|---|
| RTX 泛指工作站或消費級 GPU | RTX 5090 / RTX PRO 6000 等 | PCIe Slot |
| PCIe GPU | 指標準主機板插槽 GPU | RTX 系列 A100 PCIe H100 PCIe B200 PCIe |
| HGX 平台 | 一塊裝多顆 SXM GPU 的伺服器模組 | HGX H100 HGX B200 |
| DGX 系統 | NVIDIA 自家整機伺服器 (含 CPU、儲存、網路) | DGX H100 DGX B200 |
| NVL72 / GB200 叢集 | 超大規模 AI 系統 (多 DGX 結構) | 36 CPU: Grace 72 GPU: Blackwell |

業內實際講法舉例（工程師之間的口語）

| 語句 | 含意 |
|-----------------------|---------------------------------------|
| 這台伺服器插兩張 RTX 6000 Ada | 工作站 / 小型 AI 推理用機，PCIe 介面 |
| 我們訓練在 H100 HGX 上跑 | 使用 SXM + NVLink 平台進行分散式訓練 |
| 我們在跑 8卡 A100 | 常見的 DGX A100 配置 |
| 客戶要上 B200 PCIe | 想在一般伺服器主板上做推理 / 加速 |
| 那是 DGX H100 機櫃 | 整機 NVIDIA 官方系統 |
| GB200 NVL72 cluster | 指整合 Grace CPU + Blackwell GPU 的大型叢集架構 |

歸納成一句話：

- ◆ 「RTX」是工作站與消費級的統稱
- ◆ 「A/H/B 系列 (Data Center GPU)」是伺服器級 GPU 的統稱
- ◆ 「HGX」是伺服器 GPU 主板
- ◆ 「DGX」是完整伺服器系統
- ◆ 「SXM GPU」才有支援 NVLink，「PCIe GPU」不支援 NVLink
- ◆ 在 Hopper 與 Blackwell 世代，僅 SXM 版本支援高速 NVLink 互連

核心規格快速對照

| 項目 | A100 | H100 | B200 |
|-----------|---------------|--------------|--------------|
| 架構 | Ampere | Hopper | Blackwell |
| 製程 | 7nm | 4nm | 4nm (TSMC) |
| 記憶體 | 40/80GB HBM2e | 80GB HBM3 | 192GB HBM3e |
| FP8 效能 | - | ~2000 TFLOPS | ~4500 TFLOPS |
| NVLink | 600GB/s | 900GB/s | 1800GB/s |
| 典型價格(USD) | ~\$15K | ~\$30K | ~\$40K (預估) |

如何選擇GPU?

- 訓練 **GPT-4** 等級模型 → GB200 NVL72
- 訓練 **7B-70B** 模型 → HGX H100 (8卡)
- **LLM** 推理服務 → H100/B200 PCIe
- 微調 / **RAG** 應用 → A100 或 RTX 6000 Ada
- 開發測試 → RTX 4090 / 5090

未來展望

掌握了這些核心概念與術語層次後，未來在接續研究 Rubin 架構及其後的技術路線圖時，將能更加輕鬆上手，快速理解 NVIDIA 在 AI 運算領域的演進藍圖。